

中图法分类号: TP391 文献标识码: A 文章编号: 1006-8961(2024)11-3345-12

论文引用格式: Ji J M, Shao Y X and Ji T Z. 2024. IHCCD: dataset for identification of irregular handwritten Chinese characters. Journal of Image and Graphics, 29(11):3345-3356(季佳美, 邵允学, 季倓正. 2024. IHCCD: 非规范手写汉字识别数据集. 中国图象图形学报, 29(11):3345-3356)[DOI:10.11834/jig.230047]

IHCCD: 非规范手写汉字识别数据集

季佳美, 邵允学*, 季倓正

南京工业大学计算机与信息工程学院(人工智能学院), 南京 211816

摘要: 目的 随着深度学习技术的快速发展, 规范手写汉字识别(handwritten Chinese character recognition, HCCR)任务已经取得突破性进展, 但对非规范书写汉字识别的研究仍处于萌芽阶段。受到书法流派和书写习惯等原因影响, 手写汉字常常与打印字体差异显著, 导致同类别文字的整体结构差异非常大, 基于现有数据集训练得到的识别模型, 无法准确识别非规范书写的汉字。**方法** 为了推动非规范书写汉字识别的研究工作, 本文制做了首套非规范书写的汉字数据集(irregular handwritten Chinese character dataset, IHCCD), 目前共包含3 755个类别, 每个类别有30幅样本。还给出了经典深度学习模型ResNet, CBAM-ResNet, Vision Transformer, Swin Transformer在本文数据集上的基准性能。**结果** 实验结果表明, 虽然以上经典网络模型在规范书写的CASIA-HWDB1.1数据集上能够取得良好性能, 其中Swin Transformer在CASIA-HWDB1.1数据集上最高精度达到了95.31%, 但是利用CASIA-HWDB1.1训练集训练得到的网络模型, 在IHCCD测试集上的识别结果较差, 最高精度也只能达到30.20%。在加入IHCCD训练集后, 所有的经典模型在IHCCD测试集上的识别性能均得到了较大提升, 最高精度能达到89.89%, 这表明IHCCD数据集对非规范书写汉字识别具有研究意义。**结论** 现有OCR识别模型还存在局限性, 本文收集的IHCCD数据集能够有效增强识别模型泛化性能。该数据集下载链接<https://pan.baidu.com/s/1PtcfWj3yUSz68o2ZzvPJOQ?pwd=66Y7>。

关键词: 非规范书写; 手写汉字识别(HCCR); IHCCD数据集; 深度学习; 经典分类模型

IHCCD: dataset for identification of irregular handwritten Chinese characters

Ji Jiamei, Shao Yunxue*, Ji Tanzheng

School of Computer and Information Engineering (School of Artificial Intelligence), Nanjing Tech University, Nanjing 211816, China

Abstract: Objective With the rapid development of deep learning technology, the task of handwritten Chinese character recognition (HCCR) has made breakthrough progress. Initially, text recognition research focused primarily on the recognition of English characters and numbers. However, with the deepening of artificial intelligence technology, numerous researchers have begun to focus on the field of Chinese character recognition. In recent years, Chinese character recognition has been widely used in several application scenarios and currently has a wide range of application scenarios in the fields of bank bill recognition, mail sorting, and office automation. Chinese characters are the most widely used language in the world with the richest information meaning and are an important language carrier for people's communication. There-

收稿日期: 2023-12-21; 修回日期: 2024-03-28; 预印本日期: 2024-04-04

* 通信作者: 邵允学 csshx@njtech.edu.cn

基金项目: 钢铁冶金及资源利用省部共建教育部重点实验室2023年开放研究课题(FMRUlab23-02)

Supported by: Open Research Topics for 2023 in Key Laboratory for Ferrous Metallurgy and Resources Utilization of Ministry of Education (FMRU-lab23-02)

fore, the research on Chinese character recognition has a crucial value. However, despite these advancements, the recognition of irregular handwritten Chinese characters remains a challenging task. Handwritten Chinese characters are often influenced by various calligraphic styles and individual writing habits, leading to notable deviations from regular printed fonts. These variations can result in considerable differences in the overall structure of characters within the same category. Therefore, recognition models trained on these regular datasets may struggle to accurately identify irregularly handwritten Chinese characters encountered in real-world scenarios. For example, when sending a picture to WeChat, the text in the picture may involve sensitive words. During the identification of words by the text recognition engine, if these words are regular writing, then the engine can accurately identify and filter these sensitive words. However, some people intentionally avoid the identification of the text recognition engine due to irregular handwriting to circumvent regulation; thus, the search engine cannot recognize these words. Therefore, the research on the recognition of irregular handwritten Chinese characters is of considerable importance and can be applied in the fields of information security and filtering.

Method The dataset of irregular handwritten Chinese characters can be classified into the following types: missing or wrong order of strokes, problems with the connection or separation of strokes, maliciously enlarged or shrunken radicals, serious distortion of the character shape, saki change of the form, and excessive horizontal and vertical amplitudes, resulting in misplacement of the entire spatial structure of the characters and easily leading to ambiguities and misinterpretations. This paper collects the first irregular handwritten Chinese character dataset (IHCCD), which currently contains a total of 3 755 categories with 30 samples for each category to promote the research work on the recognition of irregular handwritten Chinese characters. In the experiment, the first 20 samples were used as training samples, and the next 10 samples were used as test samples. IHCCD is performed by different irregular handwriters who handwrite on A4 printing paper and use a scanner as the input device to convert handwritten character samples into digital image samples. These irregular handwriters do not need to write exactly according to the regular Chinese character stroke order during the dataset collection process. They can freely adjust the stroke thickness, length, and position and enlarge or reduce the radicals arbitrarily. Moreover, they can change the tilt of the Chinese characters, resulting in distorted shapes and misaligned spatial structures, bypassing the current text recognition engine. A series of image processing techniques must be adopted for the collected dataset of irregular handwritten Chinese characters. These image processing techniques, including image skew correction, single character segmentation, Otsu binarization, and character normalization, must be adopted to construct the IHCCD dataset.

Result In this paper, detailed experiments were conducted on the IHCCD and CASIA-HWDB1.1 datasets to compare the recognition performance of the classical network models, such as ResNet, CBAM-ResNet, Vision Transformer, and Swin Transformer, under different experimental settings. , and the experimental results show that although the above classical network models can achieve good performance on the canonically written CASIA-HWDB1.1 dataset. Among them, Swin Transformer achieves the highest accuracy of 95.31% on the CASIA-HWDB1.1 dataset, but the network model trained using the CASIA-HWDB1.1 training set has poor recognition results on the IHCCD test set, and the highest accuracy can only reach 30.20%. After adding the IHCCD training set, the recognition performance of all the classical models on the IHCCD test set is markedly improved, and the highest accuracy can only reach 30.20%, showing that the IHCCD dataset is crucial for the study of irregular written Chinese character recognition.

Conclusion The existing optical character recognition (OCR) recognition models still have limitations, and the dataset collected in this paper can effectively enhance the generalization performance of the recognition models. However, even for the Swin Transformer model, which has the best performance, a large gap still exists between the recognition accuracy of irregular written Chinese characters and that of regular written Chinese characters, which requires researchers to conduct further in-depth study on this problem. Link to download this dataset: <https://pan.baidu.com/s/1PtcfWj3yUSz68o2ZzvPJOQ?pwd=66Y7>.

Key words: irregular writing; handwritten Chinese character recognition (HCCR); IHCCD dataset; deep learning; classical classification model

0 引 言

手写汉字识别 (handwritten Chinese character

recognition, HCCR)不仅是模式识别的研究热点,也是汉字识别领域中最困难的研究课题之一(Shao等, 2013; Shao和Liu, 2020; 何沛松等, 2022),目前已广泛应用于银行账单识别、邮件分拣和办公自动化等

领域(Zhuang等, 2021; 乔梁等, 2023)。然而, 受到书法流派和书写习惯等原因影响, 手写汉字常常与打印字体差异显著, 导致同类别文字的整体结构差异非常大, 基于现有数据集训练得到的识别模型, 无法准确识别非规范书写的汉字。例如, 当微信聊天时发送一幅图像, 图像里的文字可能涉及敏感词汇。当文字识别引擎对这些文字进行识别时, 如果这些词汇是规范书写的, 那么引擎可以准确识别并且过滤这些敏感词汇, 但是有一部分人由于非规范手写, 故意避开文字识别引擎识别, 逃避监管, 导致搜索引擎无法识别这些文字。由此可见, 对于非规范手写汉字识别的研究具有重要意义, 可应用于信息安全、信息过滤领域。

随着手写汉字识别领域的快速发展, 公开的手写汉字数据集也越来越多。例如, 哈尔滨工业大学计算机科学与技术学院收集的 HIT-MW (Harbin Institute of Technology-multiple writers database) 数据集(Su等, 2007), 共包含 186 444 个标点、字母和汉字, 北京邮电大学信息工程系研发了 HCL2000 (handwritten character library 2000) 数据集(Zhang等, 2009), 由 1 300 名书写者书写, 共包含 1 000 份手写字符样本和对应的书写者个人信息。中国科学院自动化研究所模式识别国家实验室收集的 CASIA-HWDB1.1 (Chinese Academy of Sciences Institute of Automation handwritten Chinese character database1.1) 数据集(Liu等, 2013), 包含 3 755 个汉字类别和 171 个字符, 由 300 位书写者书写。针对这些规范书写的汉字识别研究都取得了良好的效果, 但是对于非规范手写汉字的识别问题, 目前还处于起步阶段。

近年来, 深度学习技术已广泛应用于计算机视觉领域, 解决了复杂的识别问题, 这些技术也为手写汉字识别任务带来了新的方法。Zhuang 等人(2021)提出了一种基于卷积神经网络(convolutional neural network, CNN)(Sermanet等, 2012)的手写体汉字识别模型, 该模型对输入图像进行中值滤波预处理, 在 CASIA-HWDB1.1 数据集上识别率达到 90.48%, 文中提出的中值滤波方法比传统方法准确率提高了 1.8%。Melnyk 等人(2020)提出了高性能 CNN 用于离线手写汉字识别, 通过利用具有 Bottleneck 的卷积层和全局平均操作的变化来实现, 该方法在 ICDAR-2013 (International Conference on Docu-

ment Analysis and Recognition- 2013)数据集(Yin等, 2013)上准确率提高了 0.02%, 提高了网络的可解释性。Wang 等人(2022)提出了一种端到端的残差注意力手写中文段落文本识别方法, 该方法采用残差注意力门块提取基本特征, 实现了二维文本表示法到一维文本行表示法的映射。Zhan 等人(2022)提出了将字形和语义融合嵌入(global style embeddings, GSE)并应用于离线手写中文文本识别, 并提出了一种参数化的门控融合策略, 通过融合其字形嵌入和语义嵌入来自动计算每个字符的字形语义融合嵌入。在 ICDAR-2013 竞赛数据集上取得了 96.65% 的识别率, 证明了字形语义融合嵌入的有效性。Kang 等人(2022)首次将 Transformer (Vaswani等, 2017)的自注意力机制应用于手写体文本识别, 克服了循环网络无法并行的问题, 并且在字符级别上预测手写体文本。

非规范手写的汉字数据集可分为多种类型, 包括笔画缺失或者笔画顺序错误, 笔画之间的连接或者分离出现问题, 偏旁部首被恶意放大或缩小, 字形扭曲严重, 形体畸变, 水平和竖直的幅度过大, 使得整个字符空间结构发生错乱, 容易引起歧义和误解。而目前已经收集的大多数手写汉字数据集都是基于规范书写方式的, 难以充分反映所有书写者的真实书写情况, 数据总量也不够大, 因此存在着数据集缺乏多样性的问题。针对这一问题, 本文基于深度学习方法, 围绕非规范手写汉字识别问题展开研究, 并且在该数据集上组织了一系列实验, 主要贡献有以下几点:

1) 本文收集了首套非规范手写汉字数据集(irregular handwritten Chinese character dataset, IHCCD), IHCCD 共包含 3 755 个类别, 每个类别有 30 幅样本。IHCCD 是由不同的非规范手写者在 A4 打印纸上手写完成的, 并且以扫描仪为输入设备, 将手写字符样本转换为数字图像样本。在数据集收集的过程中, 这些非规范手写者不需要完全按照标准汉字笔画顺序书写, 他们可以自由调整笔画粗细、长度和位置, 可以将部首任意放大或缩小, 可以改变汉字的倾斜程度, 使得字符形状扭曲、空间结构错乱, 从而达到避开当前文字识别引擎的目的。实验表明, 该数据集为推动非规范手写汉字识别发展奠定了基础, 促进了该领域的进一步研究和发展。

2) 本文在 IHCCD 数据集和 CASIA-HWDB1.1 数

据集上进行了详细的实验,对比了 ResNet, CBAM-ResNet, Vision Transformer, Swin Transformer 等经典网络模型在不同实验设置下的识别性能。结果表明,虽然经典网络模型在规范书写的 CASIA-HWDB1.1 数据集上能够取得良好性能,但是利用 CASIA-HWDB1.1 训练集训练得到的网络模型,在 IHCCD 测试集上的识别结果较差,在加入 IHCCD 训练集后,所有的经典模型在 IHCCD 测试集上的识别性能均得到了较大提升,显示了 IHCCD 数据集对非规范书写汉字识别研究的意义。现有 OCR(optical character recognition)识别模型尚存在局限性,本文收集的数据集能够有效增强识别模型泛化性能。但是,即便是当前性能最好的 Swin Transformer 模型,在非规范书写汉字识别问题上的识别精度与规范书写汉字识别的精度仍有较大差距,需要研究人员针对该问题进一步深入研究。

1 数据集采集与预处理

1.1 原始表格数据集采集

本文制做的 IHCCD 数据集是由不同年龄、不同性别和不同地区的学生,使用红笔在 14 行 10 列的 A4 大小网格纸上书写的,每一个字符写在一个格子里,同一类别的字符书写在同一行。在书写过程中,学生不需要完全按照标准汉字笔画顺序书写,他们可以自由调整笔画粗细、长度和位置,可以将部首任意放大或缩小,可以改变汉字的倾斜程度,从而达到避开当前文字识别引擎的目的。IHCCD 数据集共包含 3 755 个类别,每个汉字类别有 30 幅样本。然后,使用扫描仪作为输入设备,扫描精度为 600 dpi,将手写字符样本转换为数字图像样本,并将所获得的汉字图像以 jpg 文件的格式保存于计算机内,作为本文的第 1 部分数据集,部分样本如图 1 所示。

1.2 字符分割与处理

1.2.1 字符分割

在非规范手写汉字图像采集的过程中,由于扫描角度、镜头对齐等原因会使图像出现倾斜的问题,因此采用霍夫变换进行文本倾斜校正。以图 1 为例,首先提取黑色边框,接着先用 Canny 边缘检测,检测图像中明显的边缘,并将这些间断的直线边缘连接起来,利用霍夫变换概率直线检测,获得黑色直线的坐标集。解析坐标集,并标记水平线,获得偏转



图 1 非规范手写汉字样本展示
Fig. 1 Sample display of irregular handwritten Chinese characters

角度,最后将图像旋转至水平方向。其次需要去除网格线,并完成单个字符分割的工作。在样本旋转至水平方向后,为找到每行每列的起始和终止位置,根据旋转后坐标,对每行每列的最左上角和最右下角的坐标进行分析,最后平均切片得到分割后的单个字符。

由于本文制做的非规范手写的数据集是用红笔书写的,手写汉字识别本身与色彩无关,因此首先对非规范手写的汉字图像进行 B, G, R 通道的分离,以便提取纯红色笔画。图 2 即为分割后的部分非规范书写的样本示例,从而形成最终的 IHCCD 数据集。IHCCD 数据集共包含 3 755 个类别,每个类别有 30 个样本,在实验中,前 20 个样本作为训练样本,后 10 个样本作为测试样本。IHCCD 数据集的基本信息如表 1 所示。

本文第 2 部分数据集是 CASIA-HWDB1.1 数据集, CASIA-HWDB1.1 数据集和 IHCCD 数据集类别数相同,均包含 3 755 个类别。CASIA-HWDB1.1 数

表 1 IHCCD 数据集基本信息

Table 1 Basic information about the IHCCD dataset

数据集	类别数	总样本数		每一个类别样本数	
		训练集	测试集	训练集	测试集
IHCCD	3 755	75 100	37 550	20	10

据集每个类别近 300 个样本,其中包含 240 个训练样本和 60 个测试样本(Liu 等,2013)。

1. 2. 2 图像二值化

本文使用 Otsu 二值化(Otsu, 1979)做平滑细化处理,通过将汉字图像转换为黑白二值图像,使得汉

字的笔画更加突出,这样既保留了原笔迹图像的主要特征,又突出了汉字的笔画轮廓和结构。由于笔画像素值可能过于细小导致部分笔画丢失,因此通过比较周围笔画像素,用腐蚀膨胀技术来对笔画做加粗处理,这种处理方式能够有效地增强汉字的笔画信息。最后对图像做归一化处理,得到尺寸为 128×128 像素的白底黑字图像。图 3 为部分 IHCCD 数据集预处理后最终得到的效果图。CASIA-HWDB1. 1 数据集同样使用 Otsu 二值化,图像归一化处理,以进一步过滤背景噪声,保留图像信息,最终也得到尺寸为 128×128 像素的白底黑字图像。




图 2 IHCCD 数据集样本示例

Fig. 2 Examples of IHCCD dataset



图 3 IHCCD 数据集预处理后得到的效果

Fig. 3 Results after pre-processing of IHCCD dataset

2 手写汉字识别方法

深度学习是一门交叉学科,它改变了语音、图像及文字的传统识别方式,在实际应用中不断取得突破。深度学习成为机器学习领域最热门的研究内容,具有强大的特征学习能力以及分类能力。因此,本文采用以下几种经典网络模型在 IHCCD 数据集

上组织实验,验证了该数据集的有效性,并为后续研究提供了基准的结果。

2. 1 ResNet

He 等人(2016)提出了 ResNet(residual network)残差网络,引入了残差结构,通过学习残差,将部分原始输入的信息经过恒等映射层直接输到下一层,在一定程度上避免了卷积层在进行信息传递时的特征丢失(Wu 等,2019)。本文实验以 ResNet32 为基

基础,使用BasicBlock残差块,通过 3×3 卷积的堆叠来实现汉字图像的特征提取。ResNet输入的是尺寸为 128×128 像素的汉字图像,通过5次下采样,每次下采样图像大小减半,通道数翻倍,最后一次下采样得到的图像像素为 8×8 ,通道数为256,如图4所示。模型最后设计了两层全连接层,第1个全连接层输入为 $16\,384(8 \times 8 \times 256)$ 维特征向量,隐藏层为 $3\,755 \times 2$ 维特征向量;第2个全连接层的输出为 $3\,755$ 维特征向量。

为了提取关键的笔画特征信息,本文在ResNet

基础上融入了通道和空间注意力CBAM(convolutional block attention module)(Woo等,2018)机制,如图5所示。CBAM引入了通道注意力机制和空间注意力机制,空间注意力模块的输入即为通道注意力模块的输出,使模型能够更好地将注意力聚焦在笔画特征上。经过ResNet提取到的特征信息输入到attention机制进行加权,将注意力机制的输出经过平铺层转化为一维数据,最终得到融合注意力信息的输出。




图4 ResNet网络结构图
Fig. 4 The structure of ResNet




图5 CBAM-ResNet网络结构图
Fig. 5 The structure of CBAM-ResNet

2.2 Vision Transformer

Dosovitskiy等(2020)提出的ViT(vision Transformer)将自然语言处理(natural language processing, NLP)领域的思想运用到了计算机视觉(computer vision, CV)领域中。ViT模型首先将输入图像分割成不重叠的patch,每个patch包含汉字图像的不同部分。在选择patch大小时,如果patch过小,那么一个patch包含的信息较少,patch数量大,训练资源消耗大;如果patch过大,patch包含信息丰富,经Linear Projection之后可能损失部分信息导致性能变差。为了减小模型的参数量,防止模型过拟合,提高训练效率,本文选用 4×4 大小的patch。然后将每个patch经过Linear Projection层线性映射为一维向量,并且使用随机初始化的位置编码方法,将这些不重叠的patch及其位置信息的向量输入到原始Transformer模型的编码器部分中,用于进一步处理和提取特征。本文实验中设置Transformer编码器共

有12层,每层包括了MSA(multi-head self-attention)和MLP(multilayer perceptron)两个子模块,MSA将输入分成6个head,用于学习输入序列中的全局依赖关系;MLP模块用于进行局部特征的非线性变换。ViT在编码器的最后一层之后采用了全局平均池化操作,将编码器输出的序列特征转换为一个全局特征向量,最后通过全连接层对图像进行分类。ViT整体结构如图6所示。

2.3 Swin Transformer

Liu等人(2021)提出了Swin Transformer,在图像分类识别任务中达到了非常好的效果。Swin Transformer的两个主要思想是使用分层特征图和移动窗口(shifted windows),具有Transformer关注全局信息建模的能力,采用移动窗口的方法使模型可以关注到相邻窗口的相关信息,进行跨窗口的特征交互,扩大感受野(Shuai等,2022)。模型引入了CNN中常用的层级构建网络,随着网络的加深,逐步下采样可以




图 6 Vision Transformer 模型结构
Fig. 6 The structure of Vision Transformer

生成多尺度的特征,采用窗口式多头自注意力机制 (windows multi-head self-attention, W-MSA) 和移动窗口多头自注意力机制 (shifted windows multi-head self-attention, SW-MSA),将注意力的计算限制在每个不重叠的窗口内,在保证一定精度的同时减少了计算复杂度(He 等,2022)。

W-MSA 采用了对窗口内特征进行平均池化和最大池化的方式,可以有效地捕捉窗口内特征的全局关系。如图 7 所示,假设特征图大小是 $M \times M$,通过对比左右两幅图可发现窗口发生了偏移,即窗口从左上角分别向右侧和下方各偏移了 $M/2$ 像素。对于偏移后的第 L 层窗口(图 7 右侧),第 1 行第 2 列的 2×4 的窗口能够使第 $L-1$ 层的第 1 排的两个窗口进行信息交流。第 2 行第 2 列的 4×4 的窗口能够使第 $L-1$ 层的 4 个窗口进行信息交流,其他同理。因此,SW-MSA 采用移动窗口的方法使得窗口内的特征可以进行全局的交互,实现了不同窗口之间的信息交流。

Swin Transformer 总体结构如图 8 所示。Swin Transformer 堆叠了 4 个 stage,第 1 个 stage 输出特征图维度为 $32 \times 32 \times 32$,每个 stage 在该特征图上应用 Linear Embedding 层,接着堆叠两个 Swin Transformer block。Swin Transformer block 由 W-MSA 和 SW-MSA 组成,所以 Swin Transformer 的层数是 2 的整数倍。

对于 W-MSA 的计算,具体计算流程如图 9 所示。以图 8 中 stage 2 为例,首先特征图大小为 $16 \times$




图 7 W-MSA 和 SW-MSA 对图像的窗口化计算
Fig. 7 Windowing calculation of images by W-MSA and SW-MSA

16×64 ,按照 8×8 窗口大小划分为 4 个窗口,再对每个窗口单独进行自注意力计算(self attention),需要压缩窗口内的像素的高和宽得到二维矩阵,从而得到对应的 Q 、 K 、 V 值用来计算注意力,并将 Q 、 K 、 V 按照 head 的数量均分,stage 2 对应 head 数量是 6,通过 6 组不同的线性投影变换 Q 、 K 、 V ,然后并行计算注意力,每个 head 的输出结果进行拼接再通过一个线性投影得到最终输出。

为了得到多尺度的特征信息,构建了一个层级式结构,通过 Patch Merging 层进行下采样,将不同窗口内的 patch 进行合并,使特征图的大小减半,通道数翻倍,实现从局部特征到全局特征的提取。Patch Merging 类似于 CNN 中的池化层,不同之处在于 CNN 中的池化层通常会丢弃信息,例如最大池化会丢弃一个窗口内的响应值,而 Patch Merging 并不会丢弃其他响应。网络最后是全球平均池化层(global average pooling),LN (layer




图 8 Swin Transformer 模型结构
Fig. 8 Structure of Swin Transformer

norm)层,最后和一个带 softmax 的全连接层输出分类结果。




图 9 W-MSA 计算流程图
Fig. 9 Flow chart of W-MSA calculation

3 实验结果与分析

3.1 实验环境

本文实验平台环境配置情况如表 2 所示。

表 2 实验平台软硬件配置
Table 2 Experimental platform software and hardware configuration

名称	相关配置
操作系统	Windows 10
CPU	Intel(R) Xeon(R) Gold 5118 CPU @ 2.30 GHz 2.29 GHz(2 个处理器)
GPU	NVIDIA GeForce RTX 2080 Ti
深度学习框架	PyTorch

3.2 网络训练及超参数设置

训练神经网络需要提前设置网络的超参数,本文实验初始学习率设置为 0.000 1, batch size 为 64, 训练轮数 epoch 为 200。当训练模型时,利用余弦退

火方法(cosine annealinglr)(Ilya 和 Frank, 2016)衰减学习率,模型的优化算法采用自适应矩估计(adaptive moment estimation, Adam)优化算法(Kingma 和 Ba, 2015)。针对多分类任务,使用交叉熵损失函数(cross-entropy loss function)(Nasr 等, 2002),计算为

$$Loss = - \sum_{i=1}^N y^{(i)} \log \hat{y}^{(i)} \quad (1)$$

式中, N 为样本总数, $y^{(i)}$ 是标签, $\hat{y}^{(i)}$ 是预测类别为 i 的概率。当预测类别和真实标签相同时, $y^{(i)} = 1$, 否则 $y^{(i)} = 0$ 。

3.3 评价指标

为了客观地评估各种模型的性能,本文选取准确率(accuracy)作为评价指标。准确率是指正确识别的样本数量占总样本数的比值,准确率越高,说明分类器越好,具体为

$$f_{ACC} = \frac{M_{correct}}{N_{total}} \quad (2)$$

式中, N_{total} 是样本总数, $M_{correct}$ 是分类正确的样本数量。

3.4 不同模型实验结果对比分析

实验对比了 ResNet (He 等, 2016)、CBAM-ResNet (Woo 等, 2018)、Vision Transformer (Dosovitskiy 等, 2020)和 Swin Transformer(Liu 等, 2021)4个经典网络模型在不同实验设置下的识别性能。

ResNet 和 CBAM-ResNet 是基于 CNN 的方法。ViT 和 Swin Transformer 是基于 Transformer 的方法,每个 stage 的 Swin Transformer 具体参数如表 3 所示。

表 3 Swin Transformer 具体参数
Table 3 Specific parameters of Swin Transformer

参数	设置
图像尺寸	128 × 128/像素
patch 尺寸	4
维度	96
深度	[2,2,6,2]
头	[3,6,12,24]
窗口大小	8

表 4 是以上 4 种方法在 CASIA-HWDB1.1 数据集和非规范书写 IHCCD 数据集上识别精度对比的结果。其中,准确率 1 是利用 CASIA-HWDB1.1 训练集训练得到的网络模型,在 CASIA-HWDB1.1 测试

集上的识别结果;准确率 2 是利用 CASIA-HWDB1.1 训练集训练得到的网络模型,在 IHCCD 测试集上的识别结果;准确率 3 是在 CASIA-HWDB1.1 训练集中加入 IHCCD 训练集后训练得到的网络模型,在 CASIA-HWDB1.1 测试集上的识别结果;准确率 4 是在 CASIA-HWDB1.1 训练集中加入 IHCCD 训练集后训练得到的网络模型,在 IHCCD 测试集上的识别结果。

由表 4 可以看出,以上 4 种经典网络模型在规范书写的 CASIA-HWDB1.1 数据集上均取得了良好性能,其中 Swin Transformer 在 CASIA-HWDB1.1 数据集上最高精度达到了 95.31%,但是利用 CASIA-HWDB1.1 训练集训练得到的网络模型,在 IHCCD 测试集上的识别结果较差,最高精度也只能达到 30.20%。上述实验结果表明,现有 CASIA-HWDB1.1 数据集训练的模型在识别非规范书写的文字时性能不理想。在 CASIA-HWDB1.1 训练集中加入 IHCCD 训练集后,以上所有的经典模型在 CASIA-HWDB1.1 测试集上的识别性能也得到了略微提升,这是由于 CASIA-HWDB1.1 数据集本身包含一部分书写不规范的字符,而加入非规范书写的训练集能够覆盖更大范围的数据分布,与不加非规范书写数据训练的模型相比,能够更好地识别 CASIA-HWDB1.1 数据集中的非规范书写样本。在 CASIA-HWDB1.1 训练集中加入 IHCCD 训练集后,以上所有的经典模型在 IHCCD 测试集上的识别性能均得到了较大提升,最高精度达到 89.89%。以上实验结果表明,结合了本文收集的 IHCCD 数据集训练的模型,能够在大幅度提升非规范书写文字识别性能的同时,不影响甚至提升了规范书写文字识别性能。综上,实验结果表明,本文收集的 IHCCD 数据集对非规范书写汉字识别研究的意义。现有的 OCR 识别模型还存在局限性,本文收集的数据集能够有效增强识别模型泛化性能。

结合表 4 进一步分析, Swin Transformer 相比于其他 3 种经典方法识别性能更强,该方法在利用 CASIA-HWDB1.1 训练集训练得到的网络模型,在 CASIA-HWDB1.1 测试集上的识别精度分别比 ResNet、CBAM-ResNet 和 ViT 提高了 2.01%、0.9% 和 1.46%;在利用 CASIA-HWDB1.1 训练集训练得到的网络模型,在 IHCCD 测试集上的识别精度分别比 ResNet、CBAM-ResNet 和 ViT 提高了 5.97%、

3.65%和5.9%。该方法在CASIA-HWDB1.1训练集中加入IHCCD训练集后训练得到的网络模型,在CASIA-HWDB1.1测试集上的识别精度分别比ResNet、CBAM-ResNet和ViT提高了0.99%、0.8%和1.31%;在CASIA-HWDB1.1训练集中加入IHCCD训练集后训练得到的网络模型,在IHCCD测试集上识别精度分别比ResNet、CBAM-ResNet和ViT提高了11.25%、8.99%和12.95%。

CBAM-ResNet是在ResNet基础上融入了CBAM注意力机制,CBAM通过在通道上进行全局

池化来引入位置信息,相比于ResNet在一定程度上提高了识别精度,但这种方式只能捕获局部范围内的信息,而无法获取长范围依赖的信息(Hou等,2021)。ViT在全局范围内做注意力计算,计算成本较大,相比于CNN模型的不变性和局部性,特征之间依赖关系差,所以识别精度较低。Swin Transformer引入多尺度的特征,采用W-MSA和SW-MSA达到全局和局部建模的能力,将注意力的计算限制在每个不重叠的窗口内,有效地提升了分类性能。

表4 不同模型识别精度对比
Table 4 Comparison of recognition accuracy of different models

		/%			
神经网络类型	模型	准确率1	准确率2	准确率3	准确率4
CNN	ResNet(He等,2016)	93.30	24.23	94.40	78.64
	CBAM-ResNet(Woo等,2018)	94.41	26.55	94.59	80.90
Transformer	ViT(Dosovitskiy等,2020)	93.85	24.30	94.08	76.94
	Swin Transformer(Liu等,2021)	95.31	30.20	95.39	89.89

注:加粗字体表示各列最优结果。

3.5 识别结果分析

为了更清晰直观地展示非规范书写汉字的识别结果,本文使用实验结果中性能最好的Swin Transformer模型,并随机抽取了IHCCD测试集里的部分样本,图10(a)展示的是识别正确的图像示例,从图10(a)可以看出,对于结构书写清晰、笔画书写完整的样本,模型能够进行准确识别,但对于结构存在一定歧义或笔画不完整的样本,如图10(b)所示,模型的识别结果和标定的结果存在一定差异。结合图10(b)进一步分析,主要原因包括:1)汉字中相似字较多,相近的笔画和偏旁,导致汉字之间差距非常微小,再加上书写汉字时会产生一定的形变问题,使得相似字更加难以辨认;2)对于一些书写随意、笔画书写不全的汉字,识别准确率较低;3)由于非规范书写的差异性,导致同类样本空间分布较散,使得该分类问题比规范书写的文字识别问题更难,导致模型的泛化能力不足。

4 结论

本文制做了首套非规范书写的汉字数据集

IHCCD,共包含3755个类别,每个类别有30幅样本,并选择了4种经典的深度学习模型在IHCCD数据集和CASIA-HWDB1.1数据集上进一步探索和验证,实验结果表明,IHCCD数据集可以为非规范手写汉字识别研究提供数据基础。目前,非规范手写汉字识别研究仍处于起步阶段,本文仅对最常用的国标一级3755个汉字进行了识别,IHCCD数据集样本相对较少,后续将该数据集进一步扩展,并且可以考虑进行更大类别的汉字分类任务。

接下来的研究工作,可以从以下几个方面展开。一方面,本文虽然使用GPU训练,但由于汉字类别众多,所有实验也耗费了大量的时间,目前研究了4种经典网络模型在IHCCD数据集上的基准性能,未来的研究方向包括采用更多针对于规范书写字体的方法,研究其在IHCCD数据集上的测试表现,并且探究这些方法在此数据集上的局限性。其次,部首作为汉字的一部分,类别较少,结构相对简单,可以设计一种编码解码的汉字部首分析网络模型,将汉字分解为部首,采用注意力机制来进行部首提取和结构分析,基于检测到的部首和空间关系的知识,使用解码器来分析部首之间的层次结构,并据此进



图 10 部分识别结果实例

Fig. 10 Examples of partial recognition results ((a) examples of partial identified correct samples; (b) examples of partial identified incorrect samples)

行汉字识别。另一方面,汉字之间存在联系,本文对手写汉字单个字符识别做了初步研究,在此基础上,未来可以进行手写字符序列识别的研究,包括收集非规范书写的字符序列图像和非规范书写的字符序列识别等。

参考文献 (References)

Dosovitskiy A, Beyer L, Kolesnikov A, Weissenborn D, Zhai X H, Unterthiner T, Dehghani M, Minderer M, Heigold G, Gelly S, Uszkoreit J and Houlshy N. 2020. An image is worth 16×16 words: Transformers for image recognition at scale [EB/OL]. [2023-12-21]. <https://arxiv.org/pdf/2010.11929v1.pdf>

He K M, Zhang X Y, Ren S Q and Sun J. 2016. Deep residual learning for image recognition//Proceedings of 2016 IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas, USA: IEEE: 770-778 [DOI: 10.1109/CVPR.2016.90]

He P S, Li W C, Zhang J Y, Wang H X and Jiang X H. 2022. Overview of passive forensics and anti-forensics techniques for GAN-

generated image. Journal of Image and Graphics, 27(1): 88-110 (何沛松, 李伟创, 张婧媛, 王宏霞, 蒋兴浩. 2022. 面向 GAN 生成图像的被动取证及反取证技术综述. 中国图象图形学报, 27(1): 88-110) [DOI: 10.11834/jig.210430]

He X, Zhou Y, Zhao J Q, Zhang D, Yao R and Xue Y. 2022. Swin Transformer embedding UNet for remote sensing image semantic segmentation. IEEE Transactions on Geoscience and Remote Sensing, 60: #4408715 [DOI: 10.1109/TGRS.2022.3144165]

Hou Q B, Zhou D Q and Feng J S. 2021. Coordinate attention for efficient mobile network design//Proceedings of 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville, USA: IEEE: 13708-13717 [DOI: 10.1109/CVPR46437.2021.01350]

Ilya L and Frank H. 2016. SGDR: stochastic gradient descent with warm restarts. arXiv preprint arXiv: 1608.03983 [DOI: 10.48550/arXiv.1608.03983]

Kang L, Riba P, Rusiñol M, Fornés A and Villegas M. 2022. Pay attention to what you read: non-recurrent handwritten text-line recognition [EB/OL]. [2023-12-21]. <https://arxiv.org/pdf/2005.13044.pdf>

Kingma D P and Ba J. 2015. Adam: a method for stochastic optimiza-

- tion//Proceedings of the 3rd International Conference on Learning Representations. San Diego, USA: ICLR: 1-13 [DOI: 10.48550/arXiv.1412.6980]
- Liu C L, Yin F, Wang D H and Wang Q F. 2013. Online and offline handwritten Chinese character recognition: benchmarking on new databases. *Pattern Recognition*, 46(1): 155-162 [DOI: 10.1016/j.patcog.2012.06.021]
- Liu Z, Lin Y T, Cao Y, Hu H, Wei Y X, Zhang Z, Lin S and Guo B N. 2021. Swin Transformer: hierarchical vision Transformer using shifted windows//Proceedings of 2021 IEEE/CVF International Conference on Computer Vision. Montreal, Canada: IEEE: 10012-10022 [DOI: 10.1109/ICCV48922.2021.00986]
- Melnik P, You Z Q and Li K Q. 2020. A high-performance CNN method for offline handwritten Chinese character recognition and visualization. *Soft Computing*, 24(11): 7977-7987 [DOI: 10.1007/s00500-019-04083-3]
- Nasr G E, Badr E A and Joun C. 2002. Cross entropy error function in neural networks: forecasting gasoline demand//Proceedings of the 15th International Florida Artificial Intelligence Research Society Conference (FLAIRS). Florida, USA: AAAI: 381-384 [DOI: 10.5555/646815.708603]
- Otsu N. 1979. A threshold selection method from gray-level histograms. *IEEE Transactions on Systems, Man, and Cybernetics*, 9(1): 62-66 [DOI: 10.1109/TSMC.1979.4310076]
- Qiao L, Li Z S, Cheng Z Z and Li X. 2023. SCID: a Chinese characters invoice-scanned dataset in relevant to key information extraction derived of visually-rich document images. *Journal of Image and Graphics*, 28(8): 2298-2313 (乔梁, 李再升, 程战战, 李玺. 2023. SCID: 用于富含视觉信息文档图像中信息提取任务的扫描中文票据数据集. *中国图象图形学报*, 28(8): 2298-2313) [DOI: 10.11834/jig.220911]
- Sermanet P, Chintala S and LeCun Y. 2012. Convolutional neural networks applied to house numbers digit classification [EB/OL]. [2023-01-17]. <https://arxiv.org/pdf/1204.3968.pdf>
- Shao Y X and Liu C L. 2020. Teaching machines to write like humans using L-attributed grammar. *Engineering Applications of Artificial Intelligence*, 90: #103489 [DOI: 10.1016/j.engappai.2020.103489]
- Shao Y X, Wang C H and Xiao B H. 2013. Visual word density-based nonlinear shape normalization method for handwritten Chinese character recognition. *International Journal on Document Analysis and Recognition (IJDAR)*, 16(4): 387-397 [DOI: 10.1007/s10032-012-0198-4]
- Shuai X, Wang X, Wang W, Yuan X and Xu X. 2022. SAM: self attention mechanism for scene text recognition based on swin Transformer//Jónsson B Þ, Gurrin C, Tran M T, Dang-Nguyen D T, Hu A M C, Thanh B H T and Huet B, eds. *MultiMedia Modeling*. Cham, USA: Springer [DOI: 10.1007/978-3-030-98358-1_35]
- Su T H, Zhang T W and Guan D J. 2007. Corpus-based HIT-MW database for offline recognition of general-purpose Chinese handwritten text. *International Journal of Document Analysis and Recognition (IJDAR)*, 10(1): 27-38 [DOI: 10.1007/s10032-006-0037-6]
- Vaswani A, Shazeer N, Parmar N, Uszkoreit J, Jones L, Gomez A N, Kaiser L and Polosukhin I. 2017. Attention is all you need//Proceedings of the 31st International Conference on Neural Information Processing Systems. California, USA: Curran Associates Inc.: 6000-6010 [DOI: 10.5555/3295222.3295349]
- Wang Y T, Yang Y J, Chen H Y, Zheng H and Chang H Y. 2022. End-to-end handwritten Chinese paragraph text recognition using residual attention networks. *Intelligent Automation and Soft Computing*, 34(1): 371-388 [DOI: 10.32604/iasc.2022.027146]
- Woo S, Park J, Lee J and Kweon I S. 2018. CBAM: convolutional block attention module [EB/OL]. [2023-12-21]. <https://arxiv.org/pdf/1807.06521.pdf>
- Wu Z F, Shen C H and van den Hengel A. 2019. Wider or deeper: revisiting the ResNet model for visual recognition [EB/OL]. [2023-12-21]. <https://arxiv.org/pdf/1611.10080.pdf>
- Yin F, Wang Q F, Zhang X Y and Liu C L. 2013. ICDAR 2013 Chinese handwriting recognition competition//Proceedings of the 12th International Conference on Document Analysis and Recognition. Washington, USA: IEEE: 1464-1470 [DOI: 10.1109/ICDAR.2013.218]
- Zhan H J, Lyu S and Lu Y. 2022. Improving offline handwritten Chinese text recognition with glyph-semanteme fusion embedding. *International Journal of Machine Learning and Cybernetics*, 13(2): 485-496 [DOI: 10.1007/s13042-021-01420-7]
- Zhang H G, Guo J, Chen G and Li C G. 2009. HCL2000-a large-scale handwritten Chinese character database for handwritten character recognition//Proceedings of the 10th International Conference on Document Analysis and Recognition. Barcelona, Spain: IEEE: 286-289 [DOI: 10.1109/ICDAR.2009.15]
- Zhuang Y, Liu Q, Qiu C J, Wang C, Ya F, Sabbir A and Yan J Q. 2021. A handwritten Chinese character recognition based on convolutional neural network and median filtering. *Journal of Physics: Conference Series*, 1820(1): #012162 [DOI: 10.1088/1742-6596/1820/1/012162]

作者简介

季佳美,女,硕士研究生,主要研究方向为计算机视觉、模式识别和机器学习。E-mail:3121278183@qq.com

邵允学,通信作者,男,副教授,主要研究方向为计算机视觉、模式识别和机器学习。E-mail:csshyx@njtech.edu.cn

季俊正,男,硕士研究生,主要研究方向为计算机视觉、模式识别和机器学习。E-mail:jitanzh@163.com